

ABC MULTISTATE BANK

Predicción de Abandono de Clientes

Un modelo de clasificación para anticipar el churn y proteger los ingresos recurrentes del banco



Equipo de Datos · Experto en Análisis Predictivo
Desafío de Clasificación — ICS40125

El problema de negocio

ABC Bank se entera de que un cliente se va cuando ya cerró la cuenta — cuando ya es tarde para actuar

20.4%


de los clientes
abandonó el banco
(2.037 de 10.000)

Objetivo del proyecto

- 1 Analizar a los 10.000 clientes para entender qué impulsa el abandono.
- 2 Entrenar y comparar 4 modelos de clasificación (regresión logística, árbol, random forest, gradient boosting).
- 3 Traducir los resultados en acciones concretas de retención para el equipo de negocio.

Por qué importa: retener cuesta menos que adquirir, y permite actuar antes de perder al cliente — no después.

Hallazgos clave del análisis exploratorio



*Desbalance de clases ~4:1
(se abordó con class_weight y SMOTE)*

Patrones más fuertes detectados



Número de productos

7.6% de churn con 2 productos → 82.7% con 3 → 100% con 4. Relación no lineal, la señal más fuerte del dataset.



País (Alemania)

32.4% de churn en Alemania vs. ~16% en Francia y España — el doble, con un cuarto de los clientes.



Edad

Clientes que abandonan: 44.8 años en promedio, vs. 37.4 en quienes se quedan.




Saldo + actividad

Saldo alto NO protege si el cliente está inactivo: 32.8% de churn en saldo-alto + inactivo.

Comparación de modelos

4 modelos evaluados sobre el mismo conjunto de test — ROC-AUC como métrica principal



Modelo	ROC-AUC	Precisión	Recall	F1
Gradient Boosting	0.868	0.627	0.641	0.634
Random Forest	0.864	0.580	0.671	0.622
Árbol de Decisión	0.838	0.459	0.764	0.572
Regresión Logística	0.783	0.391	0.713	0.505

Gradient Boosting obtiene el mejor ROC-AUC (0.868): construye árboles de forma secuencial, corrigiendo los errores de los anteriores — captura mejor los quiebres no lineales del dataset (ej. products_number).

Umbral óptimo de decisión

Modelo: Gradient Boosting · El umbral por defecto (0.5) no es el mejor para este negocio

UMBRAL POR DEFECTO

0.50

Precisión: 62.7%

Recall: 64.1%

Pierde de vista a 1 de cada 3 clientes que sí abandonan



F2-score:
prioriza Recall

UMBRAL ÓPTIMO (F2)

0.35

Precisión: 51.0%

Recall: 77.6%

+13.5 pts de Recall a cambio de -11.8 pts de Precisión

¿Recall o Precisión?

- Un cliente perdido (falso negativo) cuesta ingresos + el costo de adquirir uno nuevo.
- Una falsa alarma (falso positivo) cuesta solo una llamada o una oferta.
- Por eso se priorizó Recall, sin descuidar del todo la Precisión.

Lectura de negocio del umbral elegido


Matriz de confusión en test (2.000 clientes) — umbral 0.35



De los 407 clientes que realmente abandonaron, el modelo detectó a 349 a tiempo (85.7% de Recall). Eso significa 349 oportunidades reales de intervención antes de perder al cliente, a cambio de 496 contactos a clientes que en realidad no se iban a ir.

¿Qué factores explican el churn?

Importancia de variables según el modelo ganador (Gradient Boosting)



Los 2 factores dominantes

Edad (37.7%)

Churn bajo hasta los 40 años, se dispara a 56.2% entre 51-60 años.

N° de productos (25.0%)

7.6% de churn con 2 productos → 82.7% con 3 → 100% con 4.

Segmento de alto riesgo

15.2% de la base = 48.3% de churn

Clientes con 3+ productos, o alemanes inactivos: 3x más churn que el resto de la base.

Acciones recomendadas por factor



Edad 41-60 años

Ejecutivo de cuenta dedicado y contacto proactivo; revisar productos de inversión/jubilación competitivos.



3+ productos contratados

Alerta automática al llegar al 3er producto: llamada de chequeo de satisfacción antes de la venta, no después.



Saldo alto + inactivo

Incentivos personalizados (mejores tasas, asesor dedicado) condicionados a reactivar el uso del banco.



Alemania (doble de churn)

Revisar precios/beneficios frente a la competencia local; reforzar atención al cliente inactivo en ese país.

Meta para el próximo trimestre

Reducir el churn total en un 10% — sin necesidad de intervenir a toda la base



Plan de ejecución

- Scoring semanal de toda la base con el modelo (umbral 0.35).
- Priorizar contacto según el segmento de riesgo dominante.
- Medir al cierre del trimestre cuántos clientes se retuvieron.

Integración en la campaña de retención

De un modelo en un notebook a un proceso continuo de negocio

1



Scoring periódico

El modelo calcula la probabilidad de churn de cada cliente cada semana.

2



Priorización

Clientes sobre el umbral 0.35 entran a una cola de retención, ordenados por riesgo.

3



Acción dirigida

Cada cliente recibe la acción según su factor de riesgo dominante (edad, productos, país).

4



Medición y reentrenamiento

Se registra el resultado de cada contacto y se reentrena el modelo cada trimestre.

En resumen

- Gradient Boosting predice el churn con AUC 0.868, superando a los otros 3 modelos.
- Con el umbral ajustado a 0.35, detectamos al 85.7% de los clientes que realmente abandonan.
- Edad, número de productos, saldo e inactividad explican la mayor parte del riesgo.
- Enfocando la retención en el 15% de clientes de mayor riesgo, el banco puede reducir el churn total en 10% el próximo trimestre.



Gracias — preguntas y discusión